

Глубинное обучение

Векторное представление текста

Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2025



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ

Генерация текста



give some examples of the types of writing AI can do, and why that will transform businesses in a paragraph.



AI can be used to write a wide range of business-related documents, including reports, proposals, and marketing materials. By utilizing AI's ability to generate ideas and provide information, businesses can quickly and easily create high-quality written materials. This can save time and resources, allowing businesses to focus on other important tasks. Additionally, AI can help ensure accuracy and consistency in writing, improving the overall professionalism and effectiveness of business documents. The use of AI in writing will transform businesses by streamlining the writing process and improving the quality and accuracy of written materials.



Машинный перевод

Яндекс Браузер

Яндекс.Браузер обновился. Версия 21.8.2

👍

💬

Закадровый перевод видео с английского

Нейросети Яндекса научились сами переводить и озвучивать видео на английском языке. Пока — не везде, но уже скоро любой ролик на английском можно будет смотреть на русском.

Сразу попробовать новую функцию можно [по ссылке](#).



Как включить перевод видео?

Hi! I'm David and I lead the NLP team at Yandex



Подписывайтесь на новости Яндекс.Браузера:

 Дзен

 ВКонтакте


 Твиттер

 Телеграм

Перевод не доступен для видео, у которых есть технические средства защиты авторских прав (DRM).

1

Голосовые помощники



Векторизация текстов

The background is a light gray canvas featuring several large, organic, overlapping shapes in muted colors: a large orange shape on the left, a blue shape at the top right, and a yellow shape at the bottom right. These shapes are decorated with various patterns: the orange shape has a dense pattern of small black dashes; the blue shape has a pattern of small white dots; the yellow shape has a pattern of small white plus signs. Additionally, there are smaller, solid-colored shapes (a blue oval and a yellow oval) and scattered wavy lines in white and black.

Задача классификации текстов

"text": "Двое налетчиков совершили нападение на охранника банка \"ЦентрКредит\" в Алматы и завладели его оружием, сообщает пресс-служба ДВД Алматы.\n\"Сегодня, в 08.10 в Центр оперативного управления ДВД города Алматы поступило сообщение о нападении на охранника одного из отделений банка \"ЦентрКредит\" в Алмалинском районе Алматы, в результате чего двое неустановленных лиц завладели его оружием\", — говорится в сообщении.\nПо неподтвержденным данным, чрезвычайное происшествие случилось в отделении, которое находится на улице Маметовой, между улицами Сейфуллина и Дзержинского.\nКак информирует ведомство, в настоящее время по городу объявлен спецплан \"Сирена\". Отрабатывается комплекс оперативных мероприятий, которые направлены на розыск и задержание преступников.\n",

"sentiment": "negative»


"text": "АСТАНА. КАЗИНФОРМ - Карим Масимов провел совещание по вопросам деятельности Актауского международного морского торгового порта. Read on the original site", "id": 2085,

"sentiment": "positive"

Мешок слов (Bag of Words)

	the	red	dog	cat	eats	food
1. the red dog →	1	1	1	0	0	0
2. cat eats dog →	0	0	1	1	1	0
3. dog eats food →	0	0	1	0	1	1
4. red cat eats →	0	1	0	1	1	0


Мешок слов (Bag of Words)



Источник: <https://towardsdatascience.com/from-word-embeddings-to-pretrained-language-models-a-new-age-in-nlp-part-1-7ed0c7f3dfc5>

Мешок слов (Bag of Words)

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...


Источник: <https://dudeperf3ct.github.io/lstm/gru/nlp/2019/01/28/Force-of-LSTM-and-GRU/>

Алгоритм решения

- ▶ Пусть есть набор текстов
- ▶ Делим каждый текст на токены и приводим слова к нормальной форме
- ▶ Используем Bag Of Words или TF-IDF, чтобы получить векторное представление каждого текста
- ▶ Используем эти вектора как вектора признаков
- ▶ Используем любые модели классификации и регрессии для анализа текстов

Мешок слов (Bag of Words)

- ▶ Слишком много признаков
- ▶ Похожие по смыслу тексты могут иметь разные представления
- ▶ Можно ли иначе получить векторные представления слов?




word2vec
skip-gram

Пример

The man loves his son

- ▶ Назовем "loves" – центральным словом
- ▶ "the", "man", "his", "son" – контекстом
- ▶ Word2vec предполагает, что вектора центрального слова и контекстных близки


Модель skip-gram



- Skip-gram модель предполагает, что контекст зависит от центрального слова:

$$P(\text{"the", "man", "his", "son"} \mid \text{"loves"})$$

Модель skip-gram



- Предположим, что распределение условно независимое:

$$P(\text{"the", "man", "his", "son"} \mid \text{"loves"}) = \\ P(\text{"the"} \mid \text{"loves"}) \times P(\text{"man"} \mid \text{"loves"}) \times P(\text{"his"} \mid \text{"loves"}) \times P(\text{"son"} \mid \text{"loves"})$$


Модель skip-gram

- ▶ Обозначим центральное слово ("loves") как w_c
- ▶ Обозначим контекстное слово ("man") как w_o
- ▶ Для слов будем искать векторные представления: $u_o, v_c \in R^d$
- ▶ Тогда опишем вероятности как:



$$P(w_o|w_c) = \frac{\exp(u_o^T v_c)}{\sum_{i \in V} \exp(u_i^T v_c)}$$

Где V – текст длиной T слов

Почему ив?



Пример



Модель skip-gram

- ▶ Тогда функция потерь word2vec модели запишем как:

$$L = - \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t) \rightarrow \min$$

- ▶ Т.е. сумма логарифмов вероятностей для всех последовательностей слов длиной $2m$
- ▶ Есть связь с функцией потерь для классификации? 😊

Пример текста

Text Corpus

Window Size = 2

The	quick	brown	fox	jumps	over	the	red	dog
The	quick	brown	fox	jumps	over	the	red	dog
The	quick	brown	fox	jumps	over	the	red	dog
The	quick	brown	fox	jumps	over	the	red	dog

Training Samples


(The , quick)
(The , brown)

(quick , the)
(quick , brown)
(quick , fox)

(brown , the)
(brown , quick)
(brown , fox)
(brown , jumps)

(fox , quick)
(fox , brown)
(fox , jumps)
(fox , over)

Пример архитектуры




Вопрос

- ▶ Матрицы W и W' - разные матрицы. Почему?

Вопрос

- ▶ Матрицы W и W' - разные матрицы. Почему?
- ▶ Пример: The man **loves** his son
- ▶ $P(\text{loves}|\text{loves}) \sim \exp(u^T v)$, где $u \in W', v \in W$
- ▶ Если $W = W'$, то $u = v$ и $P(\text{loves}|\text{loves}) \sim \exp(v^T v)$
- ▶ Но в тексте редко встречается комбинация «loves loves», поэтому $P(\text{loves}|\text{loves}) \approx 0$, что невозможно

Пример эмбедингов (векторов)



Ускорение обучения

- ▶ При подсчете условных вероятностей

$$P(w_o|w_c) = \frac{\exp(u_o^T v_c)}{\sum_{i \in V} \exp(u_i^T v_c)}$$

Требуется суммирование по всему словарю V

- ▶ Это дорогая операция во время обучения
- ▶ Как ускорить обучение модели?

Negative Sampling

- ▶ Рассмотрим $\log P(w_o|w_c)$:

$$\log P(w_o|w_c) = u_o^T v_c - \log \sum_{i \in V} \exp(u_i^T v_c)$$

- ▶ Сумму нужно как-то уменьшить 😊
- ▶ Воспользуемся идеей из бинарной классификации!

Negative Sampling

- ▶ Определим вероятность того, что два слова встречаются вместе (класс 1):

$$P(D = 1|w_c, w_o) = \sigma(u_o^T v_c)$$

- ▶ Тогда вероятность, что два слова не встречаются вместе (класс 0):

$$P(D = 0|w_c, w_o) = 1 - \sigma(u_o^T v_c)$$

- ▶ Случайным образом выберем K негативных примеров (класс 0)
- ▶ Тогда оценим $P(w_o|w_c)$ как (вероятность встретить w_o и не встретить w_k для w_c):

$$P(w_o|w_c) = P(D = 1|w_c, w_o) \prod_{k=1}^K P(D = 0|w_c, w_k)$$

Negative Sampling

- ▶ Определим вероятность того, что два слова встречаются вместе (класс 1):

$$P(D = 1|w_c, w_o) = \sigma(u_o^T v_c)$$

- ▶ Тогда вероятность, что два слова не встречаются вместе (класс 0):

$$P(D = 0|w_c, w_o) = 1 - \sigma(u_o^T v_c)$$

- ▶ Случайным образом выберем K негативных примеров (класс 0)
- ▶ Тогда переопределим $\log P(w_o|w_c)$ как (вероятность встретить w_o и не встретить w_k для w_c):

$$\log P(w_o|w_c) = \log \sigma(u_o^T v_c) - \sum_{k=1}^K \log(1 - \sigma(u_k^T v_c))$$


Negative Sampling

- ▶ K – гиперпараметр, который мы выбираем сами
- ▶ Если K маленький – меньше вычислений для функции потерь, но и меньше штраф за негативные примеры



word2vec
CBOW

Модель continuous bag of words (CBOW)



- ▶ CBOW модель предполагает, что центральное слово зависит от контекста:

$$P(\text{"loves"} \mid \text{"the", "man", "his", "son"})$$

Модель CBOW

- ▶ Обозначим центральное слово ("loves") как w_c
- ▶ Обозначим контекстное слово ("man") как w_{oi}
- ▶ Для слов будем искать векторные представления: $u_{oi}, v_c \in R^d$
- ▶ Тогда опишем вероятности как:

$$P(w_c | w_{o1}, w_{o2}, \dots, w_{o2m}) = \frac{\exp(u_c^T \bar{v}_o)}{\sum_{i \in V} \exp(u_i^T \bar{v}_o)}$$

$$\bar{v}_o = \frac{1}{2m} (v_{o1} + v_{o2} + \dots + v_{o2m})$$

Где V – текст длиной T слов


Модель CBOW

- ▶ Тогда функция потерь word2vec модели запишем как:


$$L = - \sum_{t=1}^T \log P(w_c | w_{o1}, w_{o2}, \dots, w_{o2m}) \rightarrow \min$$

- ▶ Т.е. сумма логарифмов вероятностей для всех последовательностей слов длиной $2m$

Word2vec



CBOW



Skip-gram

Проблемы word2vec

- ▶ Не учитывает структуру слов (окончания, суффиксы, приставки)
- ▶ Не использует никакой априорной информации о разных формах одного слова



FastText

Модель FastText

- ▶ Заменяем каждое слово на n токенов
 - «руслан» -> (<руслан>, <ру, рус, усл, сла, лан, ан>)
- ▶ Обучаем векторы токенов: $u_1, u_2, \dots, u_n$
- ▶ Вектор первоначального слова $z_w = \sum_{i=1}^n u_i$
- ▶ Архитектура и обучение как в word2vec

Пример



Demo

Word2Vec Demo

Training word embeddings in the browser using [TensorFlow.js](#)

Place your text below:

Hey there, Delilah. What's it like in New York city? I'm a thousand miles away. But, girl, tonight you look so pretty. Yes, you do. Times Square can't shine as bright as you. I swear it's true.

Specify model and parameters to generate dataset:

Model Skip-gram

The Word2Vec (Skip-gram) model trains words to predict their context / surrounding words.


Window size 3

☐ Negative sampling?

Generate dataset

<https://remykarem.github.io/word2vec-demo/>

Demo 2



<https://projector.tensorflow.org>

Поставьте свою оценку лекции

