

Глубинное обучение

Лекция 12

Рекуррентные нейронные сети


Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2025



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ



Анализ последовательностей

Прогноз временных рядов



Прогноз временных рядов

- ▶ Пусть дан временной ряд из T наблюдений:

$$y_1, y_2, \dots, y_t, \dots, y_{T-1}, y_T$$

- ▶ Хотим делать прогноз на один шаг вперед.
- ▶ Autoregression (AR) model для прогноза:

$$\hat{y}_{t+1} = f(y_t, y_{t-1}, \dots, y_{t-k})$$

где $f()$ – любая модель регрессии: линейная регрессия, нейронная сеть и д.р.

Прогноз временных рядов

- ▶ Как бы вы обучали модель прогноза на один шаг вперед?
- ▶ Что такое вход модели x ?
- ▶ Что такое выход модели y ?
- ▶ Какую полносвязную сеть вы бы использовали?

Прогноз временных рядов

- ▶ Autoregression (AR) model для прогноза:


$$\hat{y}_{t+1} = f(y_t, y_{t-1}, \dots, y_{t-k})$$

- ▶ На языке машинного обучения модель можем записать как условную вероятность:

$$\hat{y}_{t+1} \sim P(y_{t+1} | y_t, y_{t-1}, \dots, y_{t-k})$$


где вероятность P нужно оценить с помощью нейронных сетей

Генерация текста



Link: <https://bansalh944.medium.com/text-generation-using-lstm-b6ced8629b03>

Генерация текста



Link: <https://medium.com/@david.campion/text-generation-using-bidirectional-lstm-and-doc2vec-models-1-3-8979eb65cb3a>

Другие задачи


- ▶ Классификация временных рядов
 - По аналогии с прогнозом рядов
- ▶ Классификация текстов
 - По аналогии с генерацией текста
- ▶ Регрессии на текстах
 - По аналогии с генерацией текста
- ▶ Машинный перевод (на следующей лекции)

Мотивация

Недостатки полносвязных сетей для анализа последовательностей:

- ▶ Если в последовательности K векторов размерности D , то у полносвязной сети будет KD входов
- ▶ Потребуется больше нейронов слоях, чтобы выучит временные зависимости в данных
- ▶ Сеть будет обучаться дольше

Можно ли как-то улучшить нейронную сеть?




Полносвязные нейронные сети (напоминка)



Нейронная сеть

- ▶ Пусть дан набор наблюдений $\{x_i, y_i\}_{i=1}^n$, где $x_i \in R^d$, $y_i \in R^q$
- ▶ Построим нейронную сеть



Нейронная сеть в матричной форме

- ▶ Матрица наблюдений $X \in R^{n \times d}$ из n объектов, каждый из которых имеет d входных признаков:

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

- ▶ Число строк – число наблюдений (объектов)
- ▶ Число столбцов – число входных признаков

Нейронная сеть в матричной форме

$$\begin{aligned}H^{(1)} &= f_1(XW^{(1)} + b^{(1)}) \\H^{(2)} &= f_2(H^{(1)}W^{(2)} + b^{(2)}) \\O &= f_3(H^{(2)}W^{(3)} + b^{(3)})\end{aligned}$$

Размеры матриц:

- ▶ $X \in R^{n \times d}$, $W^{(1)} \in R^{d \times h}$, $b^{(1)} \in R^{1 \times h}$, h - число нейронов в первом слое
- ▶ $H^{(1)} \in R^{n \times h}$, $W^{(2)} \in R^{h \times m}$, $b^{(2)} \in R^{1 \times m}$, m - число нейронов во втором слое
- ▶ $H^{(2)} \in R^{n \times m}$, $W^{(3)} \in R^{m \times q}$, $b^{(3)} \in R^{1 \times q}$, q - число выходов сети
- ▶ $O \in R^{n \times q}$ - матрица прогнозов сети

Полносвязный слой

$$H^{(1)} = f_1(XW^{(1)} + b^{(1)})$$

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}, \quad W^{(1)} = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1h} \\ w_{21} & w_{22} & \cdots & w_{2h} \\ \vdots & \vdots & \vdots & \vdots \\ w_{d1} & w_{d2} & \cdots & w_{dh} \end{pmatrix}, \quad H^{(1)} = \begin{pmatrix} h_{11} & h_{12} & \cdots & h_{1h} \\ h_{21} & h_{22} & \cdots & h_{2h} \\ \vdots & \vdots & \vdots & \vdots \\ h_{n1} & h_{n2} & \cdots & h_{nh} \end{pmatrix}$$


Размеры матриц:

- ▶ $X \in R^{n \times d}$, $W^{(1)} \in R^{d \times h}$, $b^{(1)} \in R^{1 \times h}$, h - число нейронов в первом слое
- ▶ $H^{(1)} \in R^{n \times h}$ - выход слоя
- ▶ $f_1(z)$ - **функция активации**

Функции активации f


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




tanh

$$\tanh(x)$$




ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$



Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$





Рекуррентные нейронные сети (Recurrent Neural Networks)

Задача

- ▶ Пусть дано n последовательностей из T наблюдений:

$$x_1^1, x_2^1, \dots, x_t^1, \dots, x_{T-1}^1, x_T^1$$

$$x_1^2, x_2^2, \dots, x_t^2, \dots, x_{T-1}^2, x_T^2$$

...

$$x_1^n, x_2^n, \dots, x_t^n, \dots, x_{T-1}^n, x_T^n$$

где $x_t^i \in R^d$

- ▶ Хотим делать прогноз на один шаг вперед:

$$\hat{x}_{T+1}^i = f(x_1^i, x_2^i, \dots, x_t^i, \dots, x_{T-1}^i, x_T^i)$$

Задача

- ▶ Матрица наблюдений $X_t \in R^{n \times d}$ из n объектов в момент времени t , каждый из которых имеет d входных признаков:

$$X_t = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

- ▶ Число строк – число наблюдений (объектов) в момент времени t
- ▶ Число столбцов – число входных признаков

Рекуррентный нейронный слой

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$


$$O_t = f_o(H_t W_{ho} + b_o)$$

- ▶ $X_t \in R^{n \times d}$ - матрица из n наблюдений в момент времени t
- ▶ $H_t \in R^{n \times h}$ - матрица из n скрытых состояний слоя
- ▶ $W_{xh} \in R^{d \times h}$, $W_{hh} \in R^{h \times h}$, $W_{ho} \in R^{h \times o}$, h - число нейронов в слое
- ▶ $b_h \in R^{1 \times h}$, $b_o \in R^{1 \times o}$


Рекуррентный нейронный слой

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

$$O_t = f_o(H_t W_{ho} + b_o)$$




Рекуррентный нейронный слой



Обучение RNN

The background features a series of parallel diagonal lines in red, yellow, and green, creating a sense of depth and movement. These lines are reflected on a dark, glossy surface at the bottom, enhancing the abstract aesthetic.


Forward pass



Link: https://authorwhywait.github.io/blog/2021/12/02/introduction_to_dl02/


Backward pass для подсчета градиента

RNNs: Backpropagation Through Time




Проблемы с градиентами

- ▶ Информация теряется по мере прохождения во времени
- ▶ Не факт, что сеть сможет выучить зависимость финального вектора от первых векторов



Long Short-Term Memory (LSTM)

LSTM



LSTM

$$I_t = \sigma(X_t W_{xi} + H_{t-1} W_{hi} + b_i)$$

$$F_t = \sigma(X_t W_{xf} + H_{t-1} W_{hf} + b_f)$$

$$O_t = \sigma(X_t W_{xo} + H_{t-1} W_{ho} + b_o)$$

$$\tilde{C}_t = \tanh(X_t W_{xc} + H_{t-1} W_{hc} + b_c)$$

новая информация, $[-1, 1]$

$$C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t$$

добавляем новую инфо

$$H_t = O_t \odot \tanh(C_t)$$

учитываем историю


LSTM

- ▶ Позволяет предыдущему состоянию перейти в текущее без домножений на матрицы
- ▶ Модель сможет «протаскивать» информацию из начала текста в конец



Gated Recurrent Units (GRU)

GRU



GRU

$$R_t = \sigma(X_t W_{xr} + H_{t-1} W_{hr} + b_r)$$


$$Z_t = \sigma(X_t W_{xz} + H_{t-1} W_{hz} + b_z)$$

$$\tilde{H}_t = \tanh(X_t W_{xh} + (R_t \odot H_{t-1}) W_{hh} + b_h)$$

$$H_t = Z_t \odot H_{t-1} + (1 - Z_t) \odot \tilde{H}_t$$

Глубокие рекуррентные сети

Глубокие RNN



Глубокие RNN

$$H_t^1 = f(X_t W_{xh}^1 + H_{t-1}^1 W_{hh}^1 + b_h^1)$$

$$H_t^2 = f(H_t^1 W_{xh}^2 + H_{t-1}^2 W_{hh}^2 + b_h^2)$$

$$H_t^3 = f(H_t^2 W_{xh}^3 + H_{t-1}^3 W_{hh}^3 + b_h^3)$$

...


$$H_t^L = f(H_t^{L-1} W_{xh}^L + H_{t-1}^L W_{hh}^L + b_h^L)$$

$$O_t = f_o(H_t^L W_{ho} + b_o)$$

The background is a complex geometric pattern composed of numerous triangles in various shades of green and grey. The triangles are arranged in a way that creates a sense of depth and movement, with some appearing to overlap others. The overall effect is a modern, abstract design.

Двунаправленные RNN

Двунаправленные (Bidirectional) RNN



Двунаправленные (Bidirectional) RNN

$$H_t^f = f(X_t W_{xh}^f + H_{t-1}^f W_{hh}^f + b_h^f)$$
$$H_t^b = f(X_t W_{xh}^b + H_{t-1}^b W_{hh}^b + b_h^b)$$

$$H_t = \text{concat}(H_t^f, H_t^b)$$

$$O_t = f_o(H_t W_{ho} + b_o)$$

Поставьте свою оценку лекции

