

Глубинное обучение

Лекция 13

Машинный перевод. Seq2seq.


Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2025



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ




Анализ последовательностей

Прогноз временных рядов



Генерация текста



Link: <https://bansalh944.medium.com/text-generation-using-lstm-b6ced8629b03>

Задача

- ▶ Пусть дано n последовательностей из T наблюдений:

$$x_1^1, x_2^1, \dots, x_t^1, \dots, x_{T-1}^1, x_T^1$$

$$x_1^2, x_2^2, \dots, x_t^2, \dots, x_{T-1}^2, x_T^2$$

...

$$x_1^n, x_2^n, \dots, x_t^n, \dots, x_{T-1}^n, x_T^n$$

где $x_t^i \in R^d$

- ▶ Хотим делать прогноз на один шаг вперед:

$$\hat{x}_{T+1}^i = f(x_1^i, x_2^i, \dots, x_t^i, \dots, x_{T-1}^i, x_T^i)$$

Задача

- ▶ Матрица наблюдений $X_t \in R^{n \times d}$ из n объектов в момент времени t , каждый из которых имеет d входных признаков:

$$X_t = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

- ▶ Число строк – число наблюдений (объектов) в момент времени t
- ▶ Число столбцов – число входных признаков

Рекуррентный нейронный слой

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$


$$O_t = f_o(H_t W_{ho} + b_o)$$

- ▶ $X_t \in R^{n \times d}$ - матрица из n наблюдений в момент времени t
- ▶ $H_t \in R^{n \times h}$ - матрица из n скрытых состояний слоя
- ▶ $W_{xh} \in R^{d \times h}$, $W_{hh} \in R^{h \times h}$, $W_{ho} \in R^{h \times o}$, h - число нейронов в слое
- ▶ $b_h \in R^{1 \times h}$, $b_o \in R^{1 \times o}$


Рекуррентный нейронный слой


$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

$$O_t = f_o(H_t W_{ho} + b_o)$$



Рекуррентный нейронный слой




The background is a dark gray field with a faint, light gray grid of lines and dots, resembling a circuit board or a network diagram. Scattered across this field are numerous squares of various sizes and colors, including black, white, red, green, blue, and yellow. Some squares are solid, while others are outlined. They are arranged in a way that suggests a complex, interconnected system.


Типы задач с последовательностями

Типы задач


one to one




one to many




many to one



many to many



many to many




Источник: <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>

One2one


- ▶ Фиксированный размер входа и выхода
- ▶ Нет временной зависимости
- ▶ Полносвязные нейронные сети
- ▶ Задачи классификации в табличных данных и изображений (image captioning)

one to one




One2seq и seq2one

- ▶ Учитываются зависимости в последовательности
- ▶ Используются RNN
- ▶ One2seq:
 - Вход – картинка, выход – текстовое описание картинки
- ▶ Seq2one:
 - Вход – текст, выход – класс текста (sentiment analysis)



Seq2seq

- ▶ Seq2seq (1):
 - Вход – текст на русском, выход – текст на английском
 - Вход – начало текста, выход – продолжение текста (генерация текста)
- ▶ Seq2seq (2):
 - Вход – видео, выход – класс каждого кадра видео



Генерация текста

Задача

- ▶ Пусть мы хотим генерировать текст буква-за-буквой
- ▶ Для простоты рассмотрим словарь только из четырех букв [h, e, l, o]
- ▶ Для решения будем использовать RNN:

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$
$$O_t = f_o(H_t W_{ho} + b_o)$$


Пример решения задачи

- ▶ Напоминалка по RNN:

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

$$O_t = f_o(H_t W_{ho} + b_o)$$


- ▶ На выходе - вероятность следующей буквы в тексте (для всех букв в словаре)
- ▶ Как выбирать следующую букву из прогноза (несколько вариантов)?





Пример решения задачи

► Способы выбора следующей буквы из прогноза (хорошие и не очень):

- Выбирать наиболее вероятную (не очень)
- Выбирать случайную из топ-k наиболее вероятных (лучше)
- Beam search (отличный)




Обучение и генерация



Источник: https://ml-lectures.org/docs/unsupervised_learning/ml_unsupervised-2.html

Модификация



Модификация

- ▶ Генерировать текста можно не только буква-за-буквой, но и слово-за-словом
- ▶ Начинать генерацию можно с одного токена (буква, слово), так и с нескольких токенов (промт)
- ▶ Промт задает контекст на генерируемый текст
- ▶ Примеры (промт - прогноз):
 - Вопрос – ответ
 - Тема текста – текст

Demo

<https://zackproser.com/demos/tokenize>

My number is 123 985 024 55 , where 123 + 234 = 435 34


ID: 30000 "My"	ID: 30001 " number"	ID: 30002 " is"	ID: 30003 " "	ID: 30004 "123"	ID: 30005 "985"	
ID: 30006 "024"	ID: 30007 "55"	ID: 30008 ","	ID: 30009 " where"	ID: 30010 " "	ID: 30011 "123"	
ID: 30012 " +"	ID: 30013 " "	ID: 30014 "234"	ID: 30015 " ="	ID: 30016 " "	ID: 30017 "435"	ID: 30018 "34"



Beam search

Задача

- ▶ На выходе - вероятность следующей буквы в тексте (для всех букв в словаре)
- ▶ Как выбирать следующую букву из прогноза?



Жадный алгоритм

- ▶ Greedy decoding: на каждом шаге берем токен (букву или слово) с самой большой вероятностью
- ▶ Итоговой прогноз – последовательность токенов. Жадный способ на каждом шаге выбирает локальный оптимум

Неоптимальность жадного алгоритма

Прогноз с использованием жадного алгоритма

Time step	1	2	3	4
A	0.5	0.1	0.2	0.0
B	0.2	0.4	0.2	0.2
C	0.2	0.3	0.4	0.2
<eos>	0.1	0.2	0.2	0.6

Вероятность последовательности:
 $0.5 \times 0.4 \times 0.4 \times 0.6 = 0.048$

Прогноз со случайным выбором 2-го самого популярного токена на 2-м шаге

Time step	1	2	3	4
A	0.5	0.1	0.1	0.1
B	0.2	0.4	0.6	0.2
C	0.2	0.3	0.2	0.1
<eos>	0.1	0.2	0.1	0.6

Вероятность последовательности:
 $0.5 \times 0.3 \times 0.6 \times 0.6 = \mathbf{0.054}$


Beam search

- ▶ Давайте поддерживать несколько самых вероятных траекторий (**beam size**)
- ▶ Такая стратегия называется Beam Search
- ▶ Число траекторий, которое мы помним будет гиперпараметром (больше 10 брать не стоит)

Beam search

Beam size = 2


Максимальная длина
последовательности = 3



Источник: https://d2l.ai/chapter_recurrent-modern/beam-search.html

Beam search

Шаг 1:
Самые вероятные: A, C



Источник: https://d2l.ai/chapter_recurrent-modern/beam-search.html


Beam search

Шаг 2:

Перебираем пары токенов.

$P(AB) = P(A \mid \text{шаг 1}) P(B \mid \text{шаг 2})$

Топ-2 самых вероятных: AB, CE



Источник: https://d2l.ai/chapter_recurrent-modern/beam-search.html


Beam search

Шаг 3:

Перебираем пары токенов.

$$P(ABD) = P(A \mid \text{шаг 1}) P(B \mid \text{шаг 2}) \\ P(D \mid \text{шаг 3})$$

Топ-2 самых вероятных: ABD,
CED



Источник: https://d2l.ai/chapter_recurrent-modern/beam-search.html

Beam search


Итоговый прогноз:

Вариант 1:
выбираем наиболее вероятную
траекторию. Например, ABD

Вариант 2:
Можем также учитывать
промежуточные траектории. Тогда
выбираем ту, где больше:


$$\frac{1}{L} \log P(\text{траектория})$$

L – длина траектории




Источник: https://d2l.ai/chapter_recurrent-modern/beam-search.html

Специальные символы



EOS – специальный символ конца последовательности

Beam search



https://huggingface.co/docs/transformers/v4.41.0/generation_strategies

Demo 1

https://huggingface.co/spaces/m-ric/beam_search_visualizer

Beam Search Visualizer

Play with the parameters below to understand how beam search decoding works!

Here's GPT2 doing beam search decoding for you.

Parameters:

- **Sentence to decode from** (`inputs`): the input sequence to your decoder.
- **Number of steps** (`max_new_tokens`): the number of tokens to generate.
- **Number of beams** (`num_beams`): the number of beams to use.
- **Length penalty** (`length_penalty`): the length penalty to apply to outputs. `length_penalty` > 0.0 promotes longer sequences, while `length_penalty` < 0.0 encourages shorter sequences. This parameter will not impact the beam search paths, but only influence the choice of sequences in the end towards longer or shorter sequences.
- **Number of return sequences** (`num_return_sequences`): the number of sequences to be returned at the end of generation. Should be `<= num_beams`.

Sentence to decode from

Conclusion: thanks a lot. That's all for today

Number of steps

5

↺

Number of beams

4

↺

Length penalty

1

↺

Number of return sequences

3

↺

1

12

1

4

-3

3

1


4

Run




Машинный перевод

Encoder-Decoder



- ▶ На вход подаем текст на одном языке
- ▶ Encoder получает векторное представление «смысла» текста
- ▶ Полученный эмбединг подаем на вход Decoder
- ▶ Decoder генерирует перевод с учетом «смысла»

Архитектура RNN для перевода



Источник: https://github.com/yandexdataschool/nlp_course/tree/2021/week04_seq2seq

Архитектура RNN для перевода

Особенности:

- ▶ Encoder и Decoder – многослойные LSTM, GRU
- ▶ Размерность скрытых векторов порядка 1000
- ▶ Beam search для генерации

Недостатки:

- ▶ Нужно сжать весь текст в один вектор
- ▶ Теряется информация о первых словах
- ▶ Декодер тоже может терять информацию при генерации

Поставьте свою оценку лекции

