

Глубинное обучение

Лекция 14

Механизмы внимания (attention)


Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2025




НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ



Анализ последовательностей

Генерация текста




Link: <https://bansalh944.medium.com/text-generation-using-lstm-b6ced8629b03>



Рекуррентный нейронный слой

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

$$O_t = f_o(H_t W_{ho} + b_o)$$



Генерация текста: обучение и генерация



Источник: https://ml-lectures.org/docs/unsupervised_learning/ml_unsupervised-2.html


Пример решения задачи

- ▶ Напоминалка по RNN:

$$H_t = f(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$


$$O_t = f_o(H_t W_{ho} + b_o)$$

- ▶ На выходе - вероятность следующей буквы в тексте (для всех букв в словаре)



Проблемы RNN

- ▶ RNN обрабатывают последовательность токен за токеном. Последовательно.
- ▶ RNN может забывать информацию из начала последовательности.
- ▶ Это приводит к снижению качества генерируемого текста.
- ▶ Какие ваши идеи решения? 😊



Механизмы внимания


Attention

- ▶ В общем виде механизм внимания представляем в виде слоя нейронной сети:


$$\mathbf{Z} = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d}}\right)\mathbf{V}$$

- ▶ $\mathbf{Q} \in R^{(n \times d)}$ - последовательность n **ВХОДНЫХ** запросов (queries) размера d . Например, это входная последовательность токенов (слов).
- ▶ $\mathbf{K} \in R^{(m \times d)}$ - последовательность m ключей (keys) размера d . Ключи нам даны, либо мы их предварительно как-то вычисляем.
- ▶ $\mathbf{V} \in R^{(m \times v)}$ - последовательность m значений (values) размера v . Значения нам даны, либо мы их предварительно как-то вычисляем.
- ▶ $\mathbf{Z} \in R^{(n \times v)}$ - последовательность n **ВЫХОДНЫХ** значений размера v .

Attention



Attention



Self-Attention

- ▶ Пусть дана последовательность n токенов $X \in R^{(n \times k)}$. Тогда

$$Q = XW_Q, \quad W_Q \in R^{(k \times d)}$$


$$K = XW_K, \quad W_K \in R^{(k \times d)}$$

$$V = XW_V, \quad W_V \in R^{(k \times v)}$$

$$\mathbf{Z} = \text{softmax}\left(\frac{\mathbf{Q}K^T}{\sqrt{d}}\right)V$$


- ▶ W_Q, W_K, W_V - обучаемые веса, полносвязные нейронные слои
- ▶ $Q \in R^{(n \times d)}, K \in R^{(n \times d)}, V \in R^{(n \times v)}, Z \in R^{(n \times v)}$

Self-Attention




Multi-Head Attention

- ▶ Для одной входной последовательности параллельно применяем несколько механизмов внимания с разными весами.
- ▶ Результат конкатенируем в выходной вектор.




Multi-Head Attention






Demo

<https://colab.research.google.com/drive/1hXIQ77A4TYS4y3UthWF-Ci7V7vVUoxmQ?usp=sharing#scrollTo=twSVFOM9SopW>

Layer: Attention:



Self-Attention




Вопрос

- ▶ Чем self-attention отличается от полносвязного слоя?
- ▶ Чем self-attention отличается от рекуррентного слоя?




Машинный перевод

Encoder-Decoder




- ▶ На вход подаем текст на одном языке
- ▶ Encoder получает векторное представление «смысла» текста
- ▶ Полученный эмбединг подаем на вход Decoder
- ▶ Decoder генерирует перевод с учетом «смысла»

Архитектура RNN для перевода




Источник: https://github.com/yandexdataschool/nlp_course/tree/2021/week04_seq2seq

Трансформеры




Общая схема трансформера




Источник: <https://habr.com/ru/articles/486358/>


Чуть подробнее



Блок кодировщика в трансформере



Positional encoding





Self-attention не учитывает порядок слов. Чтобы это сделать, добавим positional encoding, значение которого зависит от положения токена в последовательности.

Positional encoding


Variant from the initial paper:

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{model}})$$
$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{model}})$$




A real example of positional encoding with a toy embedding size of 4

Positional encoding




<https://machinelearningmastery.com/a-gentle-introduction-to-positional-encoding-in-transformer-models-part-1/>

Positional encoding





Итоговая схема блока кодировщика


Добавили residual connection и нормализацию по слою




Layer Normalization



Теперь про декодировщики



Связь кодировщик – декодировщик



Encoder-Decoder Attention

- ▶ Выход encoder-decoder attentions считаем по обычной формуле:

$$\mathbf{Z} = \text{softmax}\left(\frac{\mathbf{Q}K_{enc}^T}{\sqrt{d}}\right)V_{enc}$$

- ▶ $\mathbf{Q} \in R^{(n \times d)}$ - последовательность n **ВХОДНЫХ** запросов (queries) размера d .
- ▶ $K_{enc} \in R^{(m \times d)}$ - берем из последнего кодировщика (encoder)
- ▶ $V_{enc} \in R^{(m \times v)}$ - берем из последнего кодировщика (encoder)
- ▶ $\mathbf{Z} \in R^{(n \times v)}$ - последовательность n **ВЫХОДНЫХ** значений размера v .


Self-attention в декодировщике

- ▶ Разрешается использовать только предыдущие слова

Выходной блок

Which word in our vocabulary
is associated with this index?


Get the index of the cell
with the highest value
(**argmax**)




Генерация перевода

- ▶ В случае с машинным переводом — «авторегрессионное» применение:
 - Сначала декодировщик выдаёт одно слово
 - Затем два (первое подаётся как вход)
 - Затем три (первые два подаются ему как вход)
 - И т.д.

Пример




Пример



Пример


Decoding time step: 1 2 3 4 **5** 6

OUTPUT I am a student <end of sentence>



Demo

<https://poloclub.github.io/transformer-explainer/>



Поставьте свою оценку лекции

